

CAHIER DES CHARGES DE STAGE

Bloc Big Data — Stack A (Environnement Légère)

Stagiaire :

Jérémie

Profil : Facilitateur pédagogique — Stack A Légère

Encadrante pédagogique	Sonia IKKEN — Coordinatrice pédagogique, CESI LINEACT
Co-encadrant recherche	Mickael Delamare — Chercheur, CESI LINEACT
Durée	5 semaines — Juin / Juillet 2026
Stack technique	Apache Hop → Parquet + MongoDB → DuckDB → dbt Core → Power BI
Infrastructure	Tout natif Windows — aucun Docker
Projet fil rouge	NutriScan — Open Food Facts (4,5M produits, format Parquet)
Cadre de recherche	Design-Based Research (DBR) — Cycle 1 Triangulation CLT + Journal + Observation

1. Contexte et enjeux du stage

1.1 Contexte pédagogique

Le CESI développe un nouveau Bloc Big Data pour les étudiants FISE INFO A3. Ce bloc est structuré en quatre boucles d'apprentissage par problèmes (B1 à B4). Le projet fil rouge est NutriScan, une startup fictive d'analyse nutritionnelle basée sur les données Open Food Facts.

1.2 Contexte de recherche — deux papiers cibles

Papier	Angle	Revue cible
P1	DBR : comment concevoir un bloc Big Data en ingénierie par PBL — démarche, décisions, itérations, comparaison Stack A vs Stack B	Education and Information Technologies (Springer, Q1)
P2	Capabilités (Sen) : impact de la complexité infrastructurelle sur les libertés effectives d'apprentissage en ingénierie des données	À définir selon les résultats du Cycle 1

1.3 Tes deux rôles

- Constructeur technique — implémenter le pipeline NutriScan complet sur Stack A (B1 à B4)
- Co-concepteur pédagogique — contribuer à la rédaction du sujet projet étudiant A3 en S5
- Participant DBR Cycle 1 — alimenter les deux papiers via les instruments de recherche

 **RECHERCHE** — La triangulation DBR repose sur trois sources : questionnaire CLT (quantitatif hebdomadaire) + journal de bord (qualitatif auto) + grille d'auto-observation (comportements concrets). L'encadrante complète une grille d'observation externe lors des points hebdomadaires. C'est cette triangulation qui donne sa robustesse scientifique aux données.

2. Projet fil rouge — NutriScan

2.1 Mise en situation

Tu intègres l'équipe data de **NutriScan**, une startup fictive spécialisée dans l'analyse nutritionnelle. La startup dispose d'un accès complet à la base Open Food Facts : 4,5 millions de produits, format Parquet, ~2,5 Go.

Le CTO te confie la mission suivante : construire un pipeline de données complet depuis l'ingestion du fichier brut jusqu'à un tableau de bord Power BI opérationnel, en utilisant une architecture Data Lake locale 3 couches.

2.2 Architecture technique — Stack A

Boucle	Outil	Action	Couche Data Lake
B1	DuckDB + DBeaver	Exploration données, modélisation dimensionnelle, DDL	sources/ → schéma vide
B2	Apache Hop + MongoDB	Pipeline ELT : Extract (Parquet) → Load (raw/ + MongoDB)	raw/ (Parquet brut)
B3	dbt Core + DuckDB + PySpark	Transform : staging + marts + semantic layer. PySpark comparatif.	silver/ + gold/
B4	DuckDB + Power BI + MongoDB	Requêtes OLAP + dashboards Power BI + MongoDB analytique	gold/ → Power BI

3. Planning semaine par semaine

Chaque vendredi à chaud : questionnaire CLT (8 min) + grille d'auto-observation (5 min) + journal de bord (10 min). Ces trois instruments sont à remplir avant 18h le vendredi — pas a posteriori.

Semaine 1 — Exploration et modélisation (B1)

Objectifs : Explorer food.parquet — Concevoir le schéma en étoile — Valider le modèle avec l'encadrante

Jour	Travail attendu
Lundi	Installation Stack A vérifiée (guide v1). Auto-positionnement initial (7 domaines). Signature consentement RGPD. Fiche démographique anonymisée. Prise en main DuckDB + DBeaver : connexion nutriScan.duckdb, premières requêtes sur food.parquet.
Mardi	Exploration approfondie food.parquet : structure des colonnes, types, volumétrie, valeurs manquantes. Découverte de la structure imbriquée des nutriments. Analyse qualité des données.
Mercredi	Conception du schéma en étoile sur papier : identifier faits, dimensions, mesures à partir des besoins NutriScan. Traiter les cas difficiles (multi-valeurs, timestamps, NULL).
Jeudi	Présentation orale du schéma à l'encadrante (15 min) — validation ou retour. Après validation : DDL dans DuckDB + requêtes JOIN à vide. Documentation data catalogue initial.
Vendredi	Finalisation B1. Instruments de recherche S1 à chaud : questionnaire CLT + grille auto-observation + journal de bord.

Semaine 2 — Pipeline ELT (B2)

Objectifs : Maîtriser Apache Hop — Pipeline ELT vers raw/ et MongoDB — Livrable 1 rendu

Jour	Travail attendu
Lundi	Prise en main Apache Hop : interface, concepts (pipeline, transform, hop). Premiers pipelines simples de lecture/écriture.
Mardi	Pipeline Extract : lecture food.parquet depuis sources/. Exploration du flux de données dans Hop.
Mercredi	Pipeline Load : écriture simultanée vers raw/ (Parquet) et MongoDB. Vérification des données dans DBeaver et shell MongoDB.
Jeudi	Pipeline ELT complet documenté. Conception du modèle de document MongoDB pour le use case application mobile NutriScan (champs retenus, justification vs modèle relationnel). Chargement de la collection nutriscan_products. 3 requêtes applicatives (recherche par EAN, liste par Nutri-Score et catégorie, classement marques). Rapport data quality initial.
Vendredi	Remise Livrable 1 (architecture + schéma + data catalogue + pipeline + modèle MongoDB + requêtes applicatives). Instruments recherche S2 à chaud.

Semaine 3 — Transformation dbt (B3)

Objectifs : Configurer dbt — Modèles staging + marts — Semantic layer — dbt test — PySpark comparatif

Jour	Travail attendu
Lundi	Configuration dbt-duckdb : profiles.yml, dbt_project.yml, sources.yml. dbt debug. Compréhension de la structure dbt.
Mardi	Modèles staging : stg_products, stg_brands, stg_categories, stg_countries, stg_date. Nettoyage et standardisation.
Mercredi	Modèles marts : fact_nutrition + 5 dimensions. Surrogate keys. Vérification cardinalités.
Jeudi	dbt test + dbt docs. Semantic layer documentée (métriques NutriScan). Session PySpark comparatif : même transformation, deux approches.
Vendredi	Remise Livrable 2 (dbt complet + semantic layer + data quality final + requêtes OLAP). Instruments recherche S3 à chaud.

Semaine 4 — OLAP et dashboards (B4)
Objectifs : 6 requêtes OLAP — Benchmarking — Dashboards Power BI — MongoDB analytique

Jour	Travail attendu
Lundi	Requêtes OLAP 1 et 2 : ROLLUP + RANK(). Interprétation métier. EXPLAIN ANALYZE.
Mardi	Requêtes OLAP 3 et 4 : PIVOT/CASE WHEN + SLICE. Benchmarking avant/après optimisation.
Mercredi	Requêtes OLAP 5 et 6 : DICE + fenêtre temporelle cumulative. Dashboard Power BI — axe qualité nutritionnelle.
Jeudi	Dashboards Power BI axes 2 et 3 (marques + temporel). MongoDB analytique (agrégations avancées).
Vendredi	Finalisation dashboards. Instruments recherche S4 à chaud.

Semaine 5 — Recherche et soutenance
Objectifs : Semaine dédiée à la recherche DBR — Co-conception sujet projet — Soutenance

Jour	Travail attendu
Lundi	Lecture des 3 articles de recherche (CLT, DBR, Capabilités). Notes personnelles.
Mardi	Session théorique avec Mickael et l'encadrante (2h). Mise en lien avec l'expérience vécue.
Mercredi	Entretien semi-directif Mickael (30 min, enregistré). Auto-positionnement final S5. Journal réflexif final.
Jeudi	Co-conception sujet projet étudiant A3 avec l'encadrante : mise en situation NutriScan, consignes par boucle, points de vigilance tuteur. Remise Livrable 3.
Vendredi	Soutenance orale (30 min) : pipeline technique + retour critique sur l'expérience Stack A + contribution à la conception pédagogique.

4. Livrables attendus

4.1 Livrables techniques (projet NutriScan)

Livable	Contenu	Rendu
L1 — Architecture et pipeline	Schéma dimensionnel documenté + data catalogue initial + architecture Data Lake + pipeline Hop documenté + modèle de document MongoDB (nutriscan_products) + 3 requêtes applicatives + rapport data quality initial	S1 + S2 + début S3 → L1 (modélisation + pipeline) 24 juin au plus tard
L2 — Implémentation et qualité	Projet dbt complet (staging + marts + tests) + semantic layer documentée + rapport data quality final + 6 requêtes OLAP avec benchmarking	Fin S3 + S4 → L2 (dbt + OLAP + dashboards) 03 juillet au plus tard
L3 — Restitution et storytelling	Dashboard Power BI (3 axes) + storytelling structuré (2 profils) + recommandations d'évolution architecture + REX technique	S5 → L3 (soutenance) + recherche 10 juillet

4.2 Livrable pédagogique

Livable	Contenu	Rendu
Contribution sujet projet étudiant A3	Co-rédaction avec l'encadrante : mise en situation NutriScan (version étudiants), consignes par boucle, points de vigilance pour le tuteur. Ce document sera utilisé dès septembre 2026.	S5 jeudi 9 juillet

4.3 Livrables de recherche

Livable	Fréquence	Alimente
Fiche démographique anonymisée	S1 lundi matin	P1 + P2 (données participants)
Auto-positionnement initial (7 domaines)	S1 lundi matin	P1 + P2
Questionnaire CLT (8 questions + ouvert)	Chaque vendredi S1→S4, à chaud	P1 (comparaison Stack A vs B)
Grille d'auto-observation (5 rubriques)	Chaque vendredi S1→S4, à chaud	P1 + P2 (comportements concrets)
Journal de bord (5 rubriques)	Chaque vendredi S1→S4, à chaud	P1 + P2 (réflexivité)
Auto-positionnement final (7 domaines)	S5 mercredi	P1 + P2 (mesure progression)
Entretien semi-directif Mickael	S5 mercredi (30 min, enregistré)	P2 (capabilités Stack A)
Formulaire de consentement RGPD signé	S1 lundi matin	Éthique recherche

5. Instruments de recherche

5.1 Fiche démographique — à remplir S1 lundi matin

💡 Cette fiche est anonymisée. Elle ne contient aucune information permettant de t'identifier personnellement. Elle sert uniquement à caractériser le profil des participants dans les articles de recherche.

Code participant (attribué par l'encadrante)	
Âge	25
Formation actuelle	4 ^e année diplôme d'ingénieur informatique
Niveau en programmation Python (0=aucun, 1=débutant, 2=intermédiaire, 3=avancé)	1
Expérience préalable avec SQL (0=jamais, 1=cours, 2=projet, 3=professionnel)	3
Outils data déjà utilisés (cocher) : Excel SQL Python/pandas Power BI Tableau Autre :	Excel, SQL, Python/pandas, Power BI
As-tu déjà entendu parler de Big Data avant ce stage ? (oui/non)	Oui
As-tu déjà utilisé Docker ou des conteneurs ? (oui/non)	Oui
Motivation principale pour ce stage (1-2 phrases libres)	Montée en compétence en big data et participer à l'amélioration d'un bloc école effectué dans le passé

5.2 Auto-positionnement — à remplir deux fois

Remplir la colonne Initial le lundi de S1. Remplir la colonne Final le mercredi de S5.

Échelle : 0 = jamais entendu parler • 1 = entendu parler, jamais pratiqué • 2 = pratiqué en projet guidé • 3 = capable de le faire seul sur un nouveau cas

Domaine	Détail	Initial S1	Final S5
1. Données & sources	Formats (CSV, JSON, Parquet), structurées/semi-structurées	2	3
2. Stockage & bases	Schéma relationnel, SQL avancé, SQL/NoSQL, data warehouse vs data lake	2	3
3. Pipelines & traitement	Ingestion, ELT/ETL, transformation, nettoyage	2	2
4. Outils & écosystème	Python data, dbt, Git, notebooks	2	2
5. Infrastructure & scalabilité	Calcul distribué, Docker, cloud, orchestration	2	2

Domaine	Détail	Initial S1	Final S5
6. Qualité & gouvernance	Détection d'anomalies, valeurs manquantes, RGPD, data catalogue	2	3
7. Visualisation & restitution	Choix de visualisation, interprétation, communication	1	2

5.3 Questionnaire CLT — à remplir chaque vendredi à chaud

Échelle : 1 = Pas du tout • 2 = Plutôt non • 3 = Neutre • 4 = Plutôt oui • 5 = Tout à fait

CHARGE INTRINSÈQUE — Complexité du contenu	
Q1 — Les concepts techniques de cette semaine m'ont semblé complexes à comprendre.	2
Q2 — J'ai eu du mal à relier les nouvelles notions à ce que je savais déjà.	3
CHARGE EXTRINSÈQUE — Complexité des outils	
Q3 — Les outils ont ajouté de la complexité sans rapport avec l'apprentissage.	1
Q4 — J'ai perdu du temps sur des problèmes d'outils plutôt que sur la compréhension.	1
Q5 — J'ai pu travailler de manière autonome sans aide externe constante.	4
CHARGE GERMANE — Apprentissage effectif	
Q6 — À la fin de cette semaine, j'ai l'impression d'avoir vraiment compris ce que j'ai fait.	4
Q7 — Je serais capable d'expliquer à quelqu'un ce que j'ai construit cette semaine.	4
Q8 — Le travail de cette semaine m'a donné envie d'approfondir.	4

Question ouverte S1 — Ce qui t'a le plus freiné / le plus aidé cette semaine :

Ce qui m'a le plus freiné : Les notions de structure imbriquée dans le fichier food.parquet, manipuler et aplatir des données complexes. Installation de Java 17 (à cause de ma version antérieur)

Ce qui m'a le plus aidé : Le workshop m'as permis de comprendre des nouvelles notions dans un point de vue pratique. Les explications de Sonia, notamment sur la méthodologie Kimball et l'intérêt de fixer le grain de la table de faits à « une ligne par produit x pays » via un UNNEST

CHARGE INTRINSÈQUE — Complexité du contenu	
Q1 — Les concepts techniques de cette semaine m'ont semblé complexes à comprendre.	3
Q2 — J'ai eu du mal à relier les nouvelles notions à ce que je savais déjà.	4
CHARGE EXTRINSÈQUE — Complexité des outils	
Q3 — Les outils ont ajouté de la complexité sans rapport avec l'apprentissage.	2

Q4 — J'ai perdu du temps sur des problèmes d'outils plutôt que sur la compréhension.	4
Q5 — J'ai pu travailler de manière autonome sans aide externe constante.	3
CHARGE GERMANE — Apprentissage effectif	
Q6 — À la fin de cette semaine, j'ai l'impression d'avoir vraiment compris ce que j'ai fait.	4
Q7 — Je serais capable d'expliquer à quelqu'un ce que j'ai construit cette semaine.	4
Q8 — Le travail de cette semaine m'a donné envie d'approfondir.	2

Question ouverte S2 — Ce qui t'a le plus freiné / le plus aidé cette semaine :

Ce qui m'a le plus freiné : J'ai mis un peu de temps à prendre en main l'interface graphique d'Apache Hop, notamment pour créer le projet ou comprendre certains champs comme les champs *Filename field* et *Metadata filename*. Mais le plus gros frein, ça a été l'erreur d'overflow Java (*Negative initial size*). Le moteur local de Hop a totalement saturé en essayant de lire les métadonnées et les structures imbriquées (STRUCT, ARRAY) du fichier du fichier source food.parquet. Ça m'a bloqué une bonne journée, car j'ai testé différentes approches dont notamment une réduction de la taille du fichier. Un autre souci auquel j'ai fait face, c'est concernant la récupération des données d'entrées, le composant « Parquet Input » lisait 0 lignes, il avait besoin d'un intermédiaire, j'ai donc ajouté le composant « Data Grid ». Il y a eu aussi des erreurs d'authentification, le fait qu'il n'y avait pas d'utilisateur pour se connecter à la base MongoDB (le workshop indiquait un admin).

Ce qui m'a le plus aidé : L'idée de prétraitement des données avec DuckDB. Au lieu de chercher à réduire la taille du fichier ou forcer la main sur Apache Hop, cela a simplifié la démarche. En forçant la conversion des colonnes complexes en chaînes simples (VARCHAR). Ça m'a aidé aussi à comprendre les différences d'utilisation ces 2 outils.

CHARGE INTRINSÈQUE — Complexité du contenu	
Q1 — Les concepts techniques de cette semaine m'ont semblé complexes à comprendre.	4
Q2 — J'ai eu du mal à relier les nouvelles notions à ce que je savais déjà.	3
CHARGE EXTRINSÈQUE — Complexité des outils	
Q3 — Les outils ont ajouté de la complexité sans rapport avec l'apprentissage.	2
Q4 — J'ai perdu du temps sur des problèmes d'outils plutôt que sur la compréhension.	4
Q5 — J'ai pu travailler de manière autonome sans aide externe constante.	2
CHARGE GERMANE — Apprentissage effectif	
Q6 — À la fin de cette semaine, j'ai l'impression d'avoir vraiment compris ce que j'ai fait.	3
Q7 — Je serais capable d'expliquer à quelqu'un ce que j'ai construit cette semaine.	3
Q8 — Le travail de cette semaine m'a donné envie d'approfondir.	2

Question ouverte S3 — Ce qui t'a le plus freiné / le plus aidé cette semaine :

Ce qui m'a le plus freiné : Dès l'Étape 1 avec un conflit de versions Python. Ma machine avait Python 3.14, ce qui faisait crasher dbt init à cause de la bibliothèque mashumaro. J'ai perdu un

peu de temps à diagnostiquer des erreurs avant de devoir réinstaller proprement Python 3.12 et recréer un environnement virtuel isolé. Lors de la couche Gold, j'ai subi un crash de mémoire : ma table de faits tournait pendant 48 minutes et a saturé près de 370 Go de swap sur mon disque dur ! C'était à cause d'un produit cartésien masqué dans mes dimensions qui n'étaient pas correctement dédoublonnées au niveau des marques et des catégories. Devoir ré-aligner tout mon SQL de staging et de marts sur le modèle en étoile de Kimball en changeant les clés logiques a été l'étape la plus complexe et chronophage. »

Ce qui m'a le plus aidé : Les retours de ma tutrice sur la déduplication stricte des dimensions. Ce qui m'a aussi beaucoup aidé, c'est la puissance des fonctions natives de DuckDB (les concaténations complexes pour remplacer INITCAP qui ne marchait pas). La comparaison des résultats avec Tom a été très utile afin de prendre du recul sur nos résultats et vérifier la cohérence des données.

CHARGE INTRINSÈQUE — Complexité du contenu	
Q1 — Les concepts techniques de cette semaine m'ont semblé complexes à comprendre.	2
Q2 — J'ai eu du mal à relier les nouvelles notions à ce que je savais déjà.	4
CHARGE EXTRINSÈQUE — Complexité des outils	
Q3 — Les outils ont ajouté de la complexité sans rapport avec l'apprentissage.	2
Q4 — J'ai perdu du temps sur des problèmes d'outils plutôt que sur la compréhension.	1
Q5 — J'ai pu travailler de manière autonome sans aide externe constante.	3
CHARGE GERMANE — Apprentissage effectif	
Q6 — À la fin de cette semaine, j'ai l'impression d'avoir vraiment compris ce que j'ai fait.	3
Q7 — Je serais capable d'expliquer à quelqu'un ce que j'ai construit cette semaine.	3
Q8 — Le travail de cette semaine m'a donné envie d'approfondir.	2

Question ouverte S4 — Ce qui t'a le plus freiné / le plus aidé cette semaine :

Ce qui m'a le plus freiné : Ce sont surtout les galères de configuration d'environnement sous Windows avec Prefect. J'ai perdu pas mal de temps au début avec des erreurs de sous-processus parce que Python ne trouvait pas mes exécutables dbt (corrigé ensuite avec shell=True), puis sur le crash DuckDB qui refusait d'écrire dans ma table pipeline_logs parce qu'elle n'était pas encore créée dans ma base de données locale.

Ce qui m'a le plus aidé : La comparaison de résultat et tableau avec Tom. Comprendre que la couche Silver (main_staging) et Gold (main_marts) n'étaient pas des dossiers Windows mais des schémas logiques à l'intérieur du fichier unique nutriScan.duckdb. Pouvoir lire précisément quel opérateur (comme HASH_GROUP_BY ou WINDOW) ralentissait mes requêtes OLAP sur DBeaver.

5.4 Grille d'auto-observation — à remplir chaque vendredi à chaud

Cette grille capture tes comportements concrets de la semaine — pas tes ressentis (c'est le journal de bord), mais les faits observables. Sois précis et factuel.

GRILLE D'AUTO-OBSERVATION — Semaine S1	
Rubrique	Ta réponse
Temps total de travail cette semaine (heures estimées)	5h / jour
Temps passé sur des problèmes d'installation/configuration vs sur le fond technique (ex: 2h config / 5h technique)	30 min config / 5h30 technique (moyenne par jour)
Nombre de fois où tu as demandé de l'aide (encadrante, internet, IA) — donne une estimation	Vingtaine de fois
Outils ou commandes qui t'ont posé le plus de difficulté cette semaine (sois précis)	Installation de Java 17, Comprendre le format parquet et l'ajustement des requêtes associé
Moment où tu t'es senti le plus autonome cette semaine — décris brièvement	Un peu sur tout mais surtout sur la partie installation
As-tu utilisé une IA générative ? Si oui, pour quoi et combien de fois ?	Oui, pour approfondir ma compréhension des nouvelles notions (avec des exemples) – Entre 10-15

GRILLE D'AUTO-OBSERVATION — Semaine S2	
Rubrique	Ta réponse
Temps total de travail cette semaine (heures estimées)	5h / jour
Temps passé sur des problèmes d'installation/configuration vs sur le fond technique (ex: 2h config / 5h technique)	1 journée pb config / reste du temps fond technique
Nombre de fois où tu as demandé de l'aide (encadrante, internet, IA) — donne une estimation	Une trentaine de fois (10 encadrante, 20 IA)
Outils ou commandes qui t'ont posé le plus de difficulté cette semaine (sois précis)	Apache Hop avec les données de type STUCT, ARRAY
Moment où tu t'es senti le plus autonome cette semaine — décris brièvement	Rédaction du Livrable 1. Les attendus étaient bien énoncés.
As-tu utilisé une IA générative ? Si oui, pour quoi et combien de fois ?	Oui, pour trouver des réponses aux erreurs, améliorer/faire les requêtes, reformulation. (20 fois)

GRILLE D'AUTO-OBSERVATION — Semaine S3	
Rubrique	Ta réponse
Temps total de travail cette semaine (heures estimées)	5h / jour

Temps passé sur des problèmes d'installation/configuration vs sur le fond technique (ex: 2h config / 5h technique)	1 journée pb config / reste du temps fond technique
Nombre de fois où tu as demandé de l'aide (encadrante, internet, IA) — donne une estimation	Une dizaine de fois (5 encadrante, 20 IA)
Outils ou commandes qui t'ont posé le plus de difficulté cette semaine (sois précis)	Dbt run (long par moment)
Moment où tu t'es senti le plus autonome cette semaine — décris brièvement	Comparaison des résultats avec Tom. Suite à la mise en place des stagings et marts, on comparé pour voir si on allait dans la bonne direction et si nos résultats était cohérent
As-tu utilisé une IA générative ? Si oui, pour quoi et combien de fois ?	Oui pour améliorer mes fichiers sql staging et marts, afin d'arriver à des résultats cohérents

GRILLE D'AUTO-OBSERVATION — Semaine S4	
Rubrique	Ta réponse
Temps total de travail cette semaine (heures estimées)	5h / jour
Temps passé sur des problèmes d'installation/configuration vs sur le fond technique (ex: 2h config / 5h technique)	Aucun problème d'installation ou autre, seulement des recherches à des erreurs mais ça fait parties de l'apprentissage
Nombre de fois où tu as demandé de l'aide (encadrante, internet, IA) — donne une estimation	Une quinzaine de fois
Outils ou commandes qui t'ont posé le plus de difficulté cette semaine (sois précis)	Nutriscan_pipeline.py, souvent des erreurs et difficile à réaliser sans l'IA
Moment où tu t'es senti le plus autonome cette semaine — décris brièvement	Rédaction du livrable 2, je savais ce qui était attendu
As-tu utilisé une IA générative ? Si oui, pour quoi et combien de fois ?	Oui Une quinzaine de fois, pour créer script Python, et reformulation sur livrable

5.5 Journal de bord — à remplir chaque vendredi à chaud

5 rubriques — 10 minutes maximum. Sois concret et honnête — pas de mise en scène.

JOURNAL DE BORD — Semaine S1	
Rubrique	Ta réponse
Observation marquante	Décris une situation concrète de la semaine : quel outil, quel problème, quelle réussite ?
Interprétation technique	Pourquoi cette situation s'est-elle produite ? Qu'as-tu compris ?
Ressenti personnel	Comment tu t'es senti cette semaine — frustré, confiant, motivé ?

Hypothèse émergente	Quel conseil donnerais-tu à un futur étudiant qui commence cette boucle ?
Question ouverte	Qu'est-ce que tu ne comprends pas encore ?

Tes réponses :

Observation :

Lors de la conception du schéma en étoile, j'ai eu du mal à déterminer comment gérer les champs multi-valeurs (pays, catégorie), donc j'ai d'abord proposé une table de pont pour gérer ça sans multiplier les lignes. Mais on m'a corrigé en m'expliquant qu'il fallait plutôt utiliser UNNEST pour adopter un grain strict d'une ligne par produit x pays, pour gérer ces champs sans devoir complexifier le schéma avec des tables de pont.

Interprétation :

Je me suis basé sur les connaissances que j'avais, en essayant de trouver une solution dans ma « zone de confort », et je n'avais pas une connaissance assez aguerrie de ce que peut faire DuckDB. J'en ai compris, qu'il est conçu pour agréger des millions de lignes instantanément grâce à des filtres sur clés numériques. J'ai mieux compris la différence entre une BDD classique et un Datawarehouse qui ne perd pas en performance à cause de plus de ligne.

Ressenti :

Je me suis senti confiant et motivé. Je renforce mes connaissances passées, en accompagnant de nouvelles notions. J'ai le sentiment que les notions sont abordables à la compréhension si je fais l'effort de « mettre ma tête dedans »

Hypothèse :

Bien prendre le temps de comprendre les notions complexes, comme le format « .parquet », les particularités de DuckDB et son moteur OLAP, analyse des besoins pour modélisation. Toute les choses pour lesquelles, on n'a généralement pas envie de prendre le temps, ces du temps qui vaut le coup d'être pris.

Question :

La façon dont nous allons utiliser UNNEST et la notion de grain d'une ligne par produit x pays

JOURNAL DE BORD — Semaine S2	
Rubrique	Ta réponse
Observation marquante	Décris une situation concrète de la semaine : quel outil, quel problème, quelle réussite ?
Interprétation technique	Pourquoi cette situation s'est-elle produite ? Qu'as-tu compris ?
Ressenti personnel	Comment tu t'es senti cette semaine — frustré, confiant, motivé ?
Hypothèse émergente	Quel conseil donnerais-tu à un futur étudiant qui commence cette boucle ?
Question ouverte	Qu'est-ce que tu ne comprends pas encore ?

Tes réponses :

Observation :

Les erreurs sur Apache Hop d'overflow Java (Negative initial size) en essayant de lire les types complexes (STRUCT, ARRAY) du fichier food.parquet brut, qui m'a fait penser et tester si c'était à cause de la taille trop importante du fichier. Ainsi que la découverte des anomalies métiers massives (plus de 100 000 Nutri-Scores incohérents avec des moyennes impossibles, des

millions de lignes à « NULL » pour certaines colonnes...etc). J'ai réussi à contourner le problème en aplatissant le fichier avec DuckDB avant de l'envoyer dans Hop.

Interprétation :

Cette situation s'est produite parce que les outils graphiques basés sur Java comme Apache Hopaturent très vite en mémoire. Donc face à des données imbriquées et massifs, ça ne fonctionne pas. Mais cela m'a permis de comprendre l'intérêt et le rôle de chaque outil ainsi que l'utilité d'un prétraitement avant d'envoyer les données tête baissée dans le flux. On laisse DuckDB gérer l'aplatissement et le typage en VARCHAR, pour que Hop puisse effectuer son travail de déplacement fluide des flux vers le Data Lake et MongoDB. Concernant les anomalies, j'ai compris qu'on ne peut jamais tirer des conclusions sans les traiter et nettoyer les données.

Ressenti :

De la frustration face aux problèmes que j'ai eue sur Hop qui avec le recul ne demandez pas autant de temps à régler, mais cela m'a permis de rechercher des solutions et essayer de comprendre le problème. Mais lorsque les données étaient accessibles et requêtables depuis le raw et MongoDB, plus de motivation pour la suite.

Hypothèse :

Ne perds pas ton temps à essayer de forcer un outil d'ingestion à faire de la transformation lourde ou à utiliser des fichiers complexes mal formatés. L'importance d'un prétraitement, peut faire gagner du temps par la suite.

Question :

Je ne comprends pas encore certaines requêtes de Mongosh et de DuckDB complexe.

JOURNAL DE BORD — Semaine S3

Rubrique	Ta réponse
Observation marquante	Décris une situation concrète de la semaine : quel outil, quel problème, quelle réussite ?
Interprétation technique	Pourquoi cette situation s'est-elle produite ? Qu'as-tu compris ?
Ressenti personnel	Comment tu t'es senti cette semaine — frustré, confiant, motivé ?
Hypothèse émergente	Quel conseil donnerais-tu à un futur étudiant qui commence cette boucle ?
Question ouverte	Qu'est-ce que tu ne comprends pas encore ?

Tes réponses :

Observation :

En remplissant la couche Gold, j'ai d'abord été bloqué par un crash de la commande dbt init à cause d'un conflit de version entre Python 3.14 et la librairie mashumaro. J'ai eu par la suite un plantage *Out of Memory* sur mon modèle fact_nutrition. La requête tournait dans le vide sans s'arrêter, et dbt a fini par saturer complètement les 370 Go d'espace libre de mon disque dur avec des fichiers de cache temporaires. Heureusement, après avoir corrigé, le dbt run s'est exécuté pendant longtemps mais sans erreur, avec des données cohérentes.

Interprétation :

Le bug d'initialisation venait du fait que dbt Core 1.8 ne supporte pas encore les nouveautés internes de Python 3.14 ; j'ai dû rétrograder mon environnement virtuel en Python 3.12. Pour le crash de mémoire sur la table de faits, c'était à cause d'un produit cartésien massif masqué. Mes tables de dimensions dim_brand et dim_category n'étaient pas de vraies tables de

références uniques : elles contenaient des doublons et gardaient le grain du produit. En joignant la table de faits sur ces dimensions géantes, DuckDB a tenté de calculer des trilliards de combinaisons en mémoire. La solution a été de forcer l'unicité par un GROUP BY dans les dimensions, et d'adapter les jointures de fact_nutrition en passant par les tables de staging comme tables de pont.

Ressenti :

J'ai alterné entre une immense frustration et une grande satisfaction. Passer des heures sur des configurations d'environnement virtuel ou voir ma machine prendre du temps à exécuter un dbt run était embêtant car je ne pouvais pas beaucoup avancer pendant que ça tournait. Par contre, le moment où le problème a été résolu, avec malgré une durée toujours longue mais de voir que mes résultats semblaient cohérents, m'a rendu super confiant.

Hypothèse :

Vérifier les dépendances de version python et ne pas forcément installer la plus récente. Ensuite, prend du recul sur tes résultats, compare, renseigne-toi, aucune erreur ne signifie pas que les résultats sont cohérents.

Question :

JOURNAL DE BORD — Semaine S4

Rubrique	Ta réponse
Observation marquante	Décris une situation concrète de la semaine : quel outil, quel problème, quelle réussite ?
Interprétation technique	Pourquoi cette situation s'est-elle produite ? Qu'as-tu compris ?
Ressenti personnel	Comment tu t'es senti cette semaine — frustré, confiant, motivé ?
Hypothèse émergente	Quel conseil donnerais-tu à un futur étudiant qui commence cette boucle ?
Question ouverte	Qu'est-ce que tu ne comprends pas encore ?

Tes réponses :

Observation :

Le moment où mon script d'orchestration `nutriscan_pipeline.py` a enfin tourné en entier sur Prefect et a fini en statut « Completed » dans mon navigateur. Après avoir corrigé les bugs de chemins Windows et automatisé la création de la table d'audit directement dans le code Python, voir dbt run, dbt test et dbt docs s'enchaîner tout seuls et injecter proprement la ligne de log finale dans DuckDB avec le statut FAILED (à cause des anomalies de la source), c'était une vraie réussite.

Interprétation :

Sous Windows, appeler un outil en ligne de commande comme dbt via un script Python nécessite obligatoirement de passer l'argument `shell=True` dans `subprocess.run`, sinon l'environnement virtuel (venv) bloque l'accès aux exécutables. Côté Data Quality, j'ai compris la distinction capitale entre un orchestrateur qui fonctionne parfaitement d'un point de vue technique et le rapport fonctionnel des données qu'il transporte (statut d'audit à FAILED en raison du manque de complétude à Open Food Facts).

Ressenti :

Un peu d'impatience avec les messages d'erreurs Python pour lancer l'automatisation des tâches. Mais en voyant ma table de faits Gold parfaitement dédoublonnée, mes métriques

sémantiques qui tournent rapidement et mes requêtes OLAP, je me sens confiant pour l'analyse via Power BI.

Hypothèse :

Pensez à ajouter des clauses de création dynamique comme CREATE TABLE IF NOT EXISTS, pour éviter de faire crasher l'orchestrateur.

Question :

Je ne comprends pas trop l'intérêt d'Apache Hop dans le bloc. Le projet peut se faire sans, sans problème.

6. Formulaire de consentement RGPD

Ce formulaire est obligatoire. Aucune donnée de recherche ne sera collectée avant sa signature. Il peut être retiré à tout moment sans conséquence sur le stage.

Je soussigné(e) Dupré Jérémie , stagiaire au CESI dans le cadre du Bloc Big Data, consens à la collecte et au traitement des données suivantes dans le cadre de la recherche DBR menée par Sonia Sikken et Mickael Delamare (CESI LINEACT) :

- Questionnaires de charge cognitive CLT (4 questionnaires hebdomadaires)
- Grilles d'auto-observation hebdomadaires (4 grilles)
- Journal de bord hebdomadaire (4 entrées)
- Auto-positionnement initial et final (7 domaines)
- Entretien semi-directif enregistré (S5, environ 30 minutes)
- Fiche démographique anonymisée

Je comprends que :

- Toutes les données sont anonymisées — mon nom n'apparaîtra dans aucune publication
- Je peux retirer mon consentement à tout moment sans conséquence sur mon stage
- Les données sont utilisées uniquement à des fins de recherche académique
- Les enregistrements audios seront supprimés après transcription

Nom et prénom	Dupré Jérémie
Date	08/06/2026
Signature	
Signature de l'encadrante	

7. Règles de fonctionnement

7.1 Validation par boucle

Chaque boucle est validée par l'encadrante avant de passer à la suivante. Présentation orale du livrable (15 min). Sans validation, la boucle est à retravailler.

7.2 Utilisation des IA génératives

Autorisée pour débloquer une erreur ou comprendre un concept. **Interdite** pour générer directement les livrables. Toute utilisation doit être tracée dans la grille d'auto-observation.

7.3 Contacts

Interlocuteur	Rôle	Pour quoi ?
Sonia Sikken	Encadrante pédagogique	Validation livrables, blocages techniques, questions sur le projet
Mickael Delamare	Co-encadrant recherche	Questions instruments de recherche, entretien S5