

CAHIER DES CHARGES DE STAGE
Bloc Big Data — Stack B (Environnement Docker)

Stagiaire :

Tom

Profil : Systèmes & Réseaux — Stack B Docker

Encadrante pédagogique	Sonia Ikken — Coordinatrice pédagogique, CESI LINEACT
Co-encadrant recherche	Mickael Delamare — Chercheur, CESI LINEACT
Durée	5 semaines — Juin / Juillet 2026
Stack technique	PySpark → MinIO + Hive Metastore → Trino → dbt-trino → Airflow → Superset + MongoDB
Infrastructure	Docker Desktop + WSL2 + docker-compose (7 services)
Projet fil rouge	NutriScan — Open Food Facts (4,5M produits, format Parquet)
Cadre de recherche	Design-Based Research (DBR) — Cycle 1 Triangulation CLT + Journal + Observation

1. Contexte et enjeux du stage

1.1 Rôles et spécificité de Tom

- Constructeur technique — implémenter le pipeline NutriScan complet sur Stack B (B1 à B4)
- Participant DBR Cycle 1 — données de comparaison Stack A vs Stack B
- Auteur du rapport de faisabilité pédagogique Stack B (future conception FISA A4)

 **RECHERCHE** — La triangulation DBR repose sur trois sources : questionnaire CLT (quantitatif hebdomadaire) + journal de bord (qualitatif auto) + grille d'auto-observation (comportements concrets). L'encadrante complète une grille d'observation externe lors des points hebdomadaires.

 **COMPARAISON** — Ta spécificité par rapport à Jérémy : tu passes une journée entière sur l'infrastructure Docker en S1 (vs 2h installation Stack A). Ce ratio infrastructure/technique est LA donnée de recherche centrale du Cycle 1 sur la charge extrinsèque.

1.2 Architecture technique — Stack B

Boucle	Outils	Action	Couche Data Lake
B1	Superset SQL Lab + Trino	Exploration données, modélisation dimensionnelle, DDL	sources/ (MinIO)
B2	PySpark → MinIO + MongoDB	Pipeline ELT : Extract (Parquet) → Load (MinIO raw/ + MongoDB)	raw/ (MinIO bronze)
B3	dbt-trino + Trino	Transform : staging + marts + semantic layer	silver/ + gold/ (MinIO)
B4	Trino + Superset dashboards	Requêtes OLAP + dashboards Superset	gold/ → Trino → Superset

2. Planning semaine par semaine

Chaque vendredi à chaud : questionnaire CLT (8 min) + grille d'auto-observation (5 min) + journal de bord (10 min). Ces trois instruments sont à remplir avant 18h le vendredi — pas a posteriori.

Semaine 1 — Infrastructure Docker et modélisation (B1)

Objectifs : Maîtriser la Stack B Docker — Explorer food.parquet via Trino — Concevoir le schéma dimensionnel

Jour	Travail attendu
Lundi matin	Installation Stack B vérifiée (guide v2). Auto-positionnement initial. Signature consentement RGPD. Fiche démographique. Lecture complète du docker-compose.yml ligne par ligne. Upload food.parquet dans MinIO bucket raw/.
Lundi après-midi	Comprendre l'architecture Docker : rôle de chaque service, ports, volumes, dépendances. Répondre par écrit : pourquoi MariaDB pour Hive ? Quel est le rôle de chaque volume ? Tester les commandes Docker essentielles.
Mardi	Mini-workshop Superset SQL Lab + Trino : créer le schéma hive.nutriscan, enregistrer food.parquet comme table externe, exploration SQL (COUNT, DESCRIBE, valeurs manquantes, valeurs aberrantes).
Mercredi	Conception du schéma en étoile sur papier. Cas difficiles (multi-valeurs, timestamps, NULL). Documentation data catalogue initial.
Jeudi	Présentation orale du schéma à l'encadrante (15 min). Après validation : DDL dans Trino (CREATE TABLE dans hive.nutriscan). Requêtes JOIN à vide.
Vendredi	Instruments de recherche S1 à chaud : questionnaire CLT + grille auto-observation + journal de bord.

 **COMPARAISON** — S1 : tu passes une journée sur l'infrastructure Docker avant de toucher aux données. Note précisément dans ta grille d'auto-observation le temps passé sur Docker vs sur la modélisation — c'est la mesure clé de la charge extrinsèque Stack B.

Semaine 2 — Pipeline ELT avec PySpark (B2)

Objectifs : Maîtriser PySpark — Pipeline vers MinIO raw/ et MongoDB — Livrable 1 rendu

Jour	Travail attendu
Lundi	Prise en main PySpark : SparkSession, lecture Parquet, premiers DataFrame. Connexion PySpark → MinIO via s3a.
Mardi	Pipeline Extract : lecture food.parquet. Exploration du DataFrame (schema, count, sample).
Mercredi	Pipeline Load MinIO : écriture en Parquet dans raw/ via s3a. Vérification dans la console MinIO.
Jeudi	Pipeline Load MongoDB : insertion dans MongoDB via pymongo. Vérification shell. Pipeline ELT complet documenté. Conception du modèle de document MongoDB pour le use case application mobile NutriScan. Chargement de la collection nutriscan_products. 3 requêtes applicatives (recherche par EAN, liste par Nutri-Score et catégorie, classement marques). Rapport data quality initial.

Jour	Travail attendu
Vendredi	Remise Livrable 1. Instruments recherche S2 à chaud.

Semaine 3 — Transformation dbt-trino (B3)

Objectifs : Configurer dbt-trino — Modèles staging + marts — Semantic layer — dbt test

Jour	Travail attendu
Lundi	Installation dbt-trino, profiles.yml, dbt_project.yml, dbt debug.
Mardi	Modèles staging : stg_products, stg_brands, stg_categories, stg_countries, stg_date.
Mercredi	Modèles marts : fact_nutrition + 5 dimensions. Surrogate keys. Vérification cardinalités.
Jeudi	dbt test + dbt docs. Semantic layer documentée. Rapport data quality final.
Vendredi	Remise Livrable 2. Instruments recherche S3 à chaud.

Semaine 4 — OLAP et dashboards Superset (B4)

Objectifs : 6 requêtes OLAP Trino — Benchmarking — 3 dashboards Superset

Jour	Travail attendu
Lundi	Requêtes OLAP 1 et 2 : ROLLUP + RANK(). EXPLAIN sur Trino. Comparaison syntaxe Trino vs DuckDB.
Mardi	Requêtes OLAP 3 et 4 : PIVOT/CASE WHEN + SLICE. Benchmarking.
Mercredi	Requêtes OLAP 5 et 6 : DICE + fenêtre temporelle cumulative. MongoDB analytique : agrégations avancées sur nutriscan_products (\$group, \$sort, \$match combinés). Dashboard Superset axe 1.
Jeudi	Dashboards Superset axes 2 et 3. Comparaison Superset vs Power BI (3 critères).
Vendredi	Instruments recherche S4 à chaud.

Semaine 5 — Recherche, rapport faisabilité et soutenance

Objectifs : Semaine dédiée à la recherche DBR — Rapport faisabilité Stack B — Soutenance

Jour	Travail attendu
Lundi	Lecture des 3 articles de recherche. Notes personnelles sur les liens avec l'expérience des 4 semaines.
Mardi	Session théorique avec Mickael et l'encadrante (2h). Mise en lien cadre DBR avec expérience vécue.
Mercredi	Entretien semi-directif Mickael (30 min, enregistré). Auto-positionnement final. Journal réflexif S5.
Jeudi	Rédaction rapport de faisabilité pédagogique Stack B (voir Section 3). Remise Livrable 3.

Jour	Travail attendu
Vendredi	Soutenance orale (30 min) : pipeline technique + retour critique Stack B + recommandations A4.

3. Livrables attendus

3.1 Livrables techniques

Livable	Contenu	Rendu
L1 — Architecture et pipeline	Schéma dimensionnel + data catalogue initial + architecture Data Lake + pipeline PySpark documenté + modèle de document MongoDB (nutriscan_products) + 3 requêtes applicatives + rapport data quality initial	S1 + S2 + début S3 → L1 (modélisation + pipeline) 24 juin au plus tard
L2 — Implémentation et qualité	Projet dbt-trino complet + semantic layer + rapport data quality final + 6 requêtes OLAP Trino avec benchmarking	Fin S3 + S4 → L2 (dbt + OLAP + dashboards) 03 juillet au plus tard
L3 — Restitution et storytelling	3 dashboards Superset + comparaison Superset vs Power BI + documentation reproductible Stack B	S5 → L3 (soutenance) + recherche 10 juillet

3.2 Livrable pédagogique — Rapport de faisabilité Stack B

Ce document alimentera directement la future conception du Bloc Big Data FISA A4 alternance

Section	Contenu attendu
Retour d'expérience structuré	Semaine par semaine : ce qui a été difficile, ce qui a bien fonctionné, combien de temps sur l'infrastructure vs sur le fond technique.
Prérequis pour un étudiant A4	Quelles compétences techniques doit maîtriser un étudiant A4 alternant avant d'aborder Stack B ? Quels outils doit-il connaître ?
Ordre d'apprentissage recommandé	Dans quel ordre découvrir les services Docker ? Quelle progression pour minimiser la charge cognitive ?
Points de vigilance techniques	Erreurs fréquentes, pièges de configuration, temps d'installation réaliste.
Comparaison Stack A vs Stack B	Du point de vue d'un utilisateur : quelle stack apporte plus de valeur selon le niveau et le contexte ? Critères : facilité, richesse, réalisme industriel.
Recommandation finale	Stack B est-elle viable pédagogiquement pour des étudiants A4 alternants ? Conditions à réunir.

3.3 Livrables de recherche

Livable	Fréquence	Alimente
Fiche démographique anonymisée	S1 lundi matin	P1 + P2 (données participants)
Auto-positionnement initial (7 domaines)	S1 lundi matin	P1 + P2
Questionnaire CLT (8 questions + ouvert)	Chaque vendredi S1→S4, à chaud	P1 (comparaison Stack A vs B)

Livrable	Fréquence	Alimente
Grille d'auto-observation (6 rubriques)	Chaque vendredi S1→S4, à chaud	P1 + P2 (comportements concrets)
Journal de bord (5 rubriques)	Chaque vendredi S1→S4, à chaud	P1 + P2 (réflexivité)
Auto-positionnement final (7 domaines)	S5 mercredi	P1 + P2 (mesure progression)
Entretien semi-directif Mickael	S5 mercredi (30 min, enregistré)	P2 (capabilités Stack B)
Formulaire de consentement RGPD signé	S1 lundi matin	Éthique recherche

4. Instruments de recherche

4.1 Fiche démographique — à remplir S1 lundi matin

 Cette fiche est anonymisée. Elle ne contient aucune information permettant de t'identifier. Elle sert à caractériser le profil des participants dans les articles de recherche.

Code participant (attribué par l'encadrante)	
Âge	21 ans
Formation actuelle	FISA A4 INFO
Niveau en programmation Python (0=aucun, 1=débutant, 2=intermédiaire, 3=avancé)	2
Expérience préalable avec SQL (0=jamais, 1=cours, 2=projet, 3=professionnel)	1
Expérience avec Docker/conteneurs (0=jamais, 1=entendu parler, 2=utilisé, 3=maîtrisé)	2
Outils data déjà utilisés (cocher) : Excel SQL Python/pandas Spark Kubernetes Autre :	Excel, Python/pandas / Talend / Microsoft SSIS
As-tu déjà administré des services réseau ou des serveurs ? (oui/non — précise)	Oui, je suis alternant administrateur système/réseau donc au quotidien
Motivation principale pour ce stage (1-2 phrases libres)	Découverte environnement recherche + aide au développement d'un bloc CESI + expérience DATA

4.2 Auto-positionnement — à remplir deux fois

Échelle : 0 = jamais entendu parler • 1 = entendu parler, jamais pratiqué • 2 = pratiqué en projet guidé • 3 = capable de le faire seul sur un nouveau cas

Domaine	Détail	Initial S1	Final S5
1. Données & sources	Formats (CSV, JSON, Parquet), structurées/semi-structurées	3	3
2. Stockage & bases	Schéma relationnel, SQL avancé, SQL/NoSQL, data warehouse vs data lake	2	3
3. Pipelines & traitement	Ingestion, ELT/ETL, transformation, nettoyage	2	3
4. Outils & écosystème	Python data, dbt, Git, notebooks, PySpark	1	2
5. Infrastructure & scalabilité	Docker, orchestration, services distribués, cloud	2	3
6. Qualité & gouvernance	Détection d'anomalies, valeurs manquantes, RGPD, data catalogue	1	2

Domaine	Détail	Initial S1	Final S5
7. Visualisation & restitution	Choix de visualisation, interprétation, communication	2	0 1 2 3

4.3 Questionnaire CLT — à remplir chaque vendredi à chaud

Échelle : 1 = Pas du tout • 2 = Plutôt non • 3 = Neutre • 4 = Plutôt oui • 5 = Tout à fait

QUESTIONNAIRE CLT — Semaine S1 À remplir le vendredi à chaud	
CHARGE INTRINSÈQUE — Complexité du contenu	
Q1 — Les concepts techniques de cette semaine m'ont semblé complexes à comprendre.	2
Q2 — J'ai eu du mal à relier les nouvelles notions à ce que je savais déjà.	2
CHARGE EXTRINSÈQUE — Complexité des outils et de l'infrastructure Docker	
Q3 — L'infrastructure Docker a ajouté de la complexité sans rapport avec l'apprentissage.	5
Q4 — J'ai perdu du temps sur des problèmes d'infrastructure plutôt que sur la compréhension.	5
Q5 — J'ai pu travailler de manière autonome sans aide externe constante.	2
CHARGE GERMANE — Apprentissage effectif	
Q6 — À la fin de cette semaine, j'ai l'impression d'avoir vraiment compris ce que j'ai fait.	4
Q7 — Je serais capable d'expliquer à quelqu'un ce que j'ai construit cette semaine.	4
Q8 — Le travail de cette semaine m'a donné envie d'approfondir.	5

Question ouverte S1 — Ce qui t'a le plus freiné / le plus aidé — et combien de temps sur Docker vs sur le fond :

Ce qui m'a le plus freiné a été les problèmes techniques liés à la stack qui m'empêchaient de faire les requêtes SQL et le workshop. J'ai eu des problèmes quasiment à chaque étape. Également le fait de ne pas pouvoir explorer les données facilement -> obligé de faire des requêtes SQL ciblées qui mettent plusieurs minutes à s'exécuter.

Ce qui m'a le plus aidé a été le workshop qui aide à bien utiliser les différents outils, c'est important d'être guidé à la découverte du projet sinon on n'avance pas car on ne connaît pas les étapes du bigdata et on ne sait pas quoi faire.

Le temps du Docker : 2.5/3 jours, découverte sujet + modélisation + pb schéma SQL 1.5 jour
C'est surtout parce que c'est la mise en place, une fois que chaque service fonctionne normalement je peux utiliser normalement chaque service et avancer sur le début.

QUESTIONNAIRE CLT — Semaine S2 À remplir le vendredi à chaud	
CHARGE INTRINSÈQUE — Complexité du contenu	
Q1 — Les concepts techniques de cette semaine m'ont semblé complexes à comprendre.	2
Q2 — J'ai eu du mal à relier les nouvelles notions à ce que je savais déjà.	2

CHARGE EXTRINSÈQUE — Complexité des outils et de l'infrastructure Docker	
Q3 — L'infrastructure Docker a ajouté de la complexité sans rapport avec l'apprentissage.	2
Q4 — J'ai perdu du temps sur des problèmes d'infrastructure plutôt que sur la compréhension.	3
Q5 — J'ai pu travailler de manière autonome sans aide externe constante.	4
CHARGE GERMANE — Apprentissage effectif	
Q6 — À la fin de cette semaine, j'ai l'impression d'avoir vraiment compris ce que j'ai fait.	4
Q7 — Je serais capable d'expliquer à quelqu'un ce que j'ai construit cette semaine.	3
Q8 — Le travail de cette semaine m'a donné envie d'approfondir.	3

Question ouverte S2 — Ce qui t'a le plus freiné / le plus aidé — et combien de temps sur Docker vs sur le fond :

Ce qui me freine le plus c'est le temps d'exécution des requêtes dans Trino. Une simple requête count ou select code prend MINIMUM 15 minutes ! C'est impossible de faire une exploration acceptable avec des temps aussi long pour chaque requête, sachant que les plus complexes peuvent durer encore plus longtemps. Par exemple je ne peux pas réaliser un data quality complet car je ne peux pas explorer chaque colonne en un temps acceptable.

Ce qui m'a le plus aidé c'est la partie 2 du Workshop. C'est très bien expliqué et ça m'a permis de bien avancer en autonomie et de comprendre comment faire la première étape du projet. Le fait de réaliser le livrable a permis en même temps de structurer le projet, de préparer les prochaines semaines et d'y voir un peu plus clair sur ce qui est attendu, les transformations à réaliser etc.

J'ai eu des problèmes techniques liés à l'installation de pyspark, j'ai dû réinstaller une bonne version de java, d'anaconda et des librairies python.

J'ai eu quelques problèmes également sur la lenteur de trino.

C'est un problème directement lié à la stack technique. Trino + hive + mariadb + minio, cela fait beaucoup de services qui doivent fonctionner ensemble, au final trino a besoin de beaucoup de ressources, mais même avec 10-12Go de RAM, mes requêtes même celles assez basiques prennent bien 10-15min à s'exécuter. C'est extrêmement problématique, surtout quand on est seul, car les requêtes sont essentielles à la réalisation du data catalogue, à l'exploration des données et au lancement du projet. Si on ne peut pas découvrir les données sources, cela ne sert à rien de continuer car on fera des actions de transformations etc totalement au hasard sans savoir si on couvre tous les cas de figures lors de la résolution des erreurs de données aberrantes/manquantes/incorrectes qui se détectent au préalable dans l'exploration du raw. C'est donc un point décisif de la stack technique, sa lenteur.

QUESTIONNAIRE CLT — Semaine S3 | À remplir le vendredi à chaud

CHARGE INTRINSÈQUE — Complexité du contenu	
Q1 — Les concepts techniques de cette semaine m'ont semblé complexes à comprendre.	4
Q2 — J'ai eu du mal à relier les nouvelles notions à ce que je savais déjà.	2
CHARGE EXTRINSÈQUE — Complexité des outils et de l'infrastructure Docker	
Q3 — L'infrastructure Docker a ajouté de la complexité sans rapport avec l'apprentissage.	1

Q4 — J'ai perdu du temps sur des problèmes d'infrastructure plutôt que sur la compréhension.	2
Q5 — J'ai pu travailler de manière autonome sans aide externe constante.	4
CHARGE GERMANE — Apprentissage effectif	
Q6 — À la fin de cette semaine, j'ai l'impression d'avoir vraiment compris ce que j'ai fait.	3
Q7 — Je serais capable d'expliquer à quelqu'un ce que j'ai construit cette semaine.	3
Q8 — Le travail de cette semaine m'a donné envie d'approfondir.	4

Question ouverte S3 — Ce qui t'a le plus freiné / le plus aidé — et combien de temps sur Docker vs sur le fond :

Ce qui m'a le plus freiné : La complexité du OLAP.

Je n'avais pas eu l'occasion de manipuler correctement avec les méthodes OLAP lors du projet CHU. Ici j'ai l'occasion de faire des requêtes OLAP variées avec au moins 6 requêtes différentes. N'ayant pas de connaissances exactes dessus, j'ai pu exécuter les requêtes mais j'ai eu du mal à comprendre vraiment comment cela fonctionnait et à quoi ça servait.

Cela reste une notion importante avant la réalisation des dashboard et il est nécessaire de la comprendre. J'ai dû utiliser l'IA pour m'aider à comprendre comment les requêtes fonctionnaient. Surement qu'avec les prosit/workshop étudiant ce sera plus clair ?

Ce qui m'a le plus aidé : La capacité que j'ai à faire du python & la clarté du workshop

Cette semaine a été passée en majorité sur les scripts python pour réaliser le silver et le gold. Le fait que le workshop soit assez guidé aide bien avec les exemples de requêtes ou la méthode de comment faire chaque étape puis je peux faire mes propres scripts après, c'est plutôt bien.

Le fait qu'on le fasse en python est bénéfique car la plupart des étudiants sont familier avec, et on ne perd pas de temps à devoir réapprendre un nouveau système / langage.

Docker sur le fond : 15 minutes, j'ai eu un problème de conteneur airflow qui voulait plus démarrer : j'ai supprimé volume et recréée et ca refonctionne. Docker n'a pas été un problème cette semaine, les temps de requêtes sont quasiment instantanés sur trino avec les tables silver/gold, surement car plus léger et moins d'array / structures complexes.

QUESTIONNAIRE CLT — Semaine S4 | À remplir le vendredi à chaud

CHARGE INTRINSÈQUE — Complexité du contenu	
Q1 — Les concepts techniques de cette semaine m'ont semblé complexes à comprendre.	1
Q2 — J'ai eu du mal à relier les nouvelles notions à ce que je savais déjà.	1
CHARGE EXTRINSÈQUE — Complexité des outils et de l'infrastructure Docker	
Q3 — L'infrastructure Docker a ajouté de la complexité sans rapport avec l'apprentissage.	2
Q4 — J'ai perdu du temps sur des problèmes d'infrastructure plutôt que sur la compréhension.	2
Q5 — J'ai pu travailler de manière autonome sans aide externe constante.	5
CHARGE GERMANE — Apprentissage effectif	
Q6 — À la fin de cette semaine, j'ai l'impression d'avoir vraiment compris ce que j'ai fait.	4

Q7 — Je serais capable d'expliquer à quelqu'un ce que j'ai construit cette semaine.	4
Q8 — Le travail de cette semaine m'a donné envie d'approfondir.	5

Question ouverte S4 — Ce qui t'a le plus freiné / le plus aidé — et combien de temps sur Docker vs sur le fond :

Ce qui m'a le plus freiné : Le problème avec airflow, j'ai dû réinstaller et repasser sur du debug docker alors que j'étais retourné dans le côté projet. Ça s'est bien passé quand même et j'ai réussi à debug sans perdre trop de temps ou rester bloquer donc c'est OK.

Ce qui m'a le plus aidé : Le workshop toujours très utile, le fait que les vues et les premiers exemples soient donnés facilitent et favorisent l'apprentissage et la compréhension des outils/process.

Temps docker : Pas longtemps sur l'infra docker en elle-même. J'ai surtout fait du python et de l'airflow cette semaine. C'était genre 1j max a debug le docker a cause de airflow sinon c'était purement du python et travailler sur le fond du sujet. 15H sur le reste.

4.4 Grille d'auto-observation — à remplir chaque vendredi à chaud

Rubrique spécifique Stack B : le ratio infrastructure/technique est la donnée de recherche centrale. Sois précis sur les temps.

GRILLE D'AUTO-OBSERVATION — Semaine S1	
Rubrique	Ta réponse
Temps total de travail cette semaine (heures estimées)	22h (de lundi après-midi à jeudi soir)
Temps passé sur infrastructure Docker vs fond technique (ex: 3h Docker / 4h technique)	Installation Docker 2h Debug problèmes trino hive superset 10h Debug problèmes schema 2h Modélisation 3h Prepa livrable 1h30 Premières requêtes 1H30 2H workshop 1 (sur la compréhension)
Services Docker qui t'ont posé le plus de difficulté (sois précis : lequel, pourquoi)	- Trino : Problèmes liés à un manque de RAM dans la config par défaut (4Go) alors que le fichier à traiter fait 7Go, ce qui m'a donné des erreurs sur les requêtes SQL dans superset - Hive-metastore : Manque des jars dans le Docker ce qui cause des erreurs - Superset : Pas à cause de Superset mais j'ai eu les requêtes SQL + Schéma qui étaient différent du fichier food.parquet donc des erreurs.
Nombre de fois où tu as demandé de l'aide (encadrante, internet, IA)	Encadrante : 7 (Trino bug, Trino Ram, Hive-Metastore erreur, SQL erreur, Schema Erreur, colonne inexistante) Internet & IA : 5-10 fois dans la semaine pour tenter de corriger les erreurs du docker & revoir les bases de la modélisation

Moment où tu t'es senti le plus autonome cette semaine	Sur la modélisation du schéma et l'exploration des données. J'ai pu tout faire sans autre accompagnement que les documents et j'ai pu manipuler la stack moi-même.
As-tu utilisé une IA générative ? Si oui, pour quoi et combien de fois ?	Oui Copilot, 5-10 fois max. pour résoudre les erreurs techniques ou pour reformuler des requêtes SQL. Egalement pour le concept de modélisation.

GRILLE D'AUTO-OBSERVATION — Semaine S2

Rubrique	Ta réponse
Temps total de travail cette semaine (heures estimées)	20h de travail effectif, 1/2 livrable 1/2 workshop + requêtes découvertes
Temps passé sur infrastructure Docker vs fond technique (ex: 3h Docker / 4h technique)	2h à debug pyspark & reinstall (java/ env conda) & 3H pour comprendre chaque étape du script ingestion python raw avec pyspark vers mongodb. + rajouter les logs etc. Assez simple, sans erreurs à l'exécution finale 3h passées sur mongodb pour tester la database, comprendre le fonctionnement des tables, des produits, de réaliser la complétude et les statistiques sur les données etc. Le reste c'est principalement la réalisation du livrable, forcément plus compliqué et long quand on est tout seul.
Services Docker qui t'ont posé le plus de difficulté (sois précis : lequel, pourquoi)	Trino uniquement à cause du temps d'exécution de chaque requête comme expliqué dans le CLT S2.
Nombre de fois où tu as demandé de l'aide (encadrante, internet, IA)	2 fois encadrante pour le schéma IA quelquefois pour compléter mon code python et faire des requêtes trino notamment pour tester et explorer le dataset pour faire le rapport data quality
Moment où tu t'es senti le plus autonome cette semaine	Rédaction livrable, workshop2
As-tu utilisé une IA générative ? Si oui, pour quoi et combien de fois ?	Oui pour générer des requêtes pour explorer les données et faire les requêtes data quality

GRILLE D'AUTO-OBSERVATION — Semaine S3

Rubrique	Ta réponse
Temps total de travail cette semaine (heures estimées)	20h
Temps passé sur infrastructure Docker vs fond technique (ex: 3h Docker / 4h technique)	Très peu passé de temps sur docker en lui-même. J'ai eu des problèmes avec pyspark a cause de jar manquantes, résolu en 1 demi-journée. J'ai surtout passé du temps a faire les scripts python gold et silver, puis toutes les requêtes et tables trino assez long, compter 2-3j seul. Pas eu le temps de finir les dag airflow / automatisation

Services Docker qui t'ont posé le plus de difficulté (sois précis : lequel, pourquoi)	Pas de problèmes particuliers a part les jars manquantes dans pyspark. Il faut les rajouter dans la configuration de sparksession
Nombre de fois où tu as demandé de l'aide (encadrante, internet, IA)	Encadrante : 2 fois Internet : quelques IA ; 5-10 pour aide requête et python
Moment où tu t'es senti le plus autonome cette semaine	Réaliser les script silver et gold, on peut le faire en autonomie (uniquement si le schéma est bien réalisé au préalable)
As-tu utilisé une IA générative ? Si oui, pour quoi et combien de fois ?	Oui, 5-10 fois pour aide requête et python scripts, debug des erreurs ou voir des exemples.

GRILLE D'AUTO-OBSERVATION — Semaine S4	
Rubrique	Ta réponse
Temps total de travail cette semaine (heures estimées)	19h
Temps passé sur infrastructure Docker vs fond technique (ex: 3h Docker / 4h technique)	Pas de temps passé sur Docker cette semaine, seulement sur les outils (superset, airflow).
Services Docker qui t'ont posé le plus de difficulté (sois précis : lequel, pourquoi)	Airflow -> J'ai du faire une image custom pour ajouter les jar et java nécessaire pour l'exécution du pipeline avec Pyspark, si ces ajouts ne sont pas faits, le DAG refuse de se lancer.
Nombre de fois où tu as demandé de l'aide (encadrante, internet, IA)	IA : Pour debug l'image docker airflow et compléter mes scripts pipeline
Moment où tu t'es senti le plus autonome cette semaine	Intégration des dags et réalisation des tests // data quality rapport, j'ai pu faire ça en totale autonomie et en me détachant un peu du workshop
As-tu utilisé une IA générative ? Si oui, pour quoi et combien de fois ?	Oui, 5-6 fois pour m'aider à faire les script pyspark ou des requêtes pour le data quality, cela simplifie de ne pas avoir a écrire 15 requêtes a la main.

4.5 Journal de bord — à remplir chaque vendredi à chaud

JOURNAL DE BORD — Semaine S1	
Rubrique	Ta réponse
Observation marquante	Décris une situation concrète : quel service Docker, quel outil, quel problème ou réussite ?
Interprétation technique	Pourquoi cette situation s'est-elle produite ? Qu'as-tu compris sur l'infrastructure ou les outils ?
Ressenti personnel	Comment tu t'es senti cette semaine — frustré, confiant, motivé ?
Hypothèse émergente	Quel conseil donnerais-tu à un futur étudiant A4 qui commence Stack B ?
Question ouverte	Qu'est-ce que tu ne comprends pas encore ?

Tes réponses :

Observation :

La mise en place de la stack Docker. Au lancement du docker les services fonctionnent bien, mais dès la première utilisation de trino, hive, superset j'ai eu des problèmes multiples (Ram, crash, schéma, requêtes incorrectes etc.) Finalement, j'ai trop perdu de temps et je n'ai pas pu découvrir le sujet dans des conditions idéales.

Interprétation :

La situation s'est produite à cause de la diversité de la stack. Chaque élément n'est pas forcément interopérable directement avec ce qui est fourni dans les images Docker, il faut donc faire des modifications. Aussi à cause du format des données (parquet) difficile à analyser avec la stack (pas d'outil graphique simple et rapide pour visualiser les données)

Ressenti :

C'est assez frustrant d'être coupé à chaque étape par des problèmes techniques, Au final quand ça fonctionne enfin, j'ai pris confiance et j'ai pu effectuer des requêtes multiples pour découvrir les données.

Hypothèse :

Bien lire tous les documents de départ. Passer du temps sur l'installation car faire tout fonctionner dès le début évitera de perdre du temps par la suite, donc bien tester chaque service même si on s'en sert qu'en semaine 2/3/4.

Question :

Je n'ai pas encore bien compris la différence entre Airflow et Pyspark et pourquoi utiliser les 2 et pas juste Airflow. Je découvrirais sûrement cela dans les semaines prochaines.

JOURNAL DE BORD — Semaine S2

Rubrique	Ta réponse
Observation marquante	Décris une situation concrète : quel service Docker, quel outil, quel problème ou réussite ?
Interprétation technique	Pourquoi cette situation s'est-elle produite ? Qu'as-tu compris sur l'infrastructure ou les outils ?
Ressenti personnel	Comment tu t'es senti cette semaine — frustré, confiant, motivé ?
Hypothèse émergente	Quel conseil donnerais-tu à un futur étudiant A4 qui commence Stack B ?
Question ouverte	Qu'est-ce que tu ne comprends pas encore ?

Tes réponses :

Observation :

Semaine 2: Problème lancement pyspark à cause de Java et de Anaconda. Résolu en réinstallant proprement, voir script install.

Erreur de chemin dans le premier script python. Modification facile.

Ensuite lancement du script pyspark, assez simple à comprendre. C'est une insertion classique vers une bdd, rien d'incompréhensible si on a déjà fait du python auparavant.

J'ai un doute sur l'ordre du workshop sur le moment où on doit charger à la main le fichier food.parquet dans MinIO pour finalement faire exactement la même chose dans pyspark. Autant faire pyspark plus tôt, ça permet de faire avancer directement.

J2- Finir la modélisation, avec quelques points bloquants sur les dates et quelques champs manquants. Finalement cela reste cohérent et je pense relativement facile à faire si on sait les règles de création du schéma de modélisation

J3-4 : réalisation du livrable, difficultés à faire le data quality a cause de trino lenteur. Sinon RAS.

J5 : finition du dataquality et rajout des logs dans le pipeline pyspark & mongodb

Interprétation :

C'est lors de cette semaine que j'ai compris que la stack n'était pas optimisée pour un projet bigdata comme celui-ci. En soit, l'infrastructure est fonctionnelle, je peux utiliser chaque service, c'est plutôt d'un point de vue performance que ça freine. En effet, ne pas pouvoir faire de requête à cause de la lenteur intra-conteneurs docker est problématique et inconcevable en production. Je ne sais pas si c'est le fichier parquet qui est trop gros, mal formaté, le stack trop peu interopérable intra service mais le fait est que c'est lent et que cela rend le travail plus complexe sans aucune valeur ajoutée pour le projet. Ça nous apprend juste à mesurer l'impact de nos requêtes : si elles sont mal écrites on perd 10-15 minutes à chaque fois. Pour pyspark c'est surtout un problème d'information sur comment l'installer, si on n'a ni anaconda ni java, on ne peut pas savoir qu'il faut les installer et en quelles versions. Il faut donc aller voir dans la documentation et résoudre les erreurs. Pourquoi pas cela nous apprend à chercher nous-même et ce n'est pas très long à faire fonctionner.

Ressenti :

C'est à la fois frustrant car on perd du temps et on aimerait avancer plus vite sur le projet. Mais en même temps c'est confortant de passer du temps au début pour bien orienter le projet, savoir quoi faire à chaque étape, connaître chaque service et son utilité dans la stack.

Hypothèse :

Ne pas juste copier-coller du code ou des requêtes, il faut vraiment comprendre pourquoi on les fait, sans comprendre, si on change de sujet on sera incapable de refaire le projet ou un autre projet similaire.

Aussi bien prendre son temps sur la modélisation car c'est la base du projet. Une mauvaise modélisation empêchera de faire de bons dashboards par la suite.

Question :

Trino reste encore assez flou pour moi surtout sur les requêtes agrégées complexes.

JOURNAL DE BORD — Semaine S3

Rubrique	Ta réponse
Observation marquante	Décris une situation concrète : quel service Docker, quel outil, quel problème ou réussite ?
Interprétation technique	Pourquoi cette situation s'est-elle produite ? Qu'as-tu compris sur l'infrastructure ou les outils ?
Ressenti personnel	Comment tu t'es senti cette semaine — frustré, confiant, motivé ?
Hypothèse émergente	Quel conseil donnerais-tu à un futur étudiant A4 qui commence Stack B ?
Question ouverte	Qu'est-ce que tu ne comprends pas encore ?

Tes réponses :

Observation :

Pyspark est un outil puissant et assez simple d'utilisation. Tant qu'on sait coder en python, on peut utiliser pyspark sans problème pour faire le traitement. Il faut simplement s'assurer de bien connaître la structure de son document sinon on aura des erreurs. Pyspark permet de faire la découverte de ce schéma et simplifie donc à la fois l'exploration des données mais aussi le traitement raw silver gold. J'ai également eu des problèmes et j'ai du refaire certaines choses notamment le schéma gold dans trino, j'ai eu des changements de modélisation à cause d'un mauvais grain dans mon traitement.

Interprétation :

J'ai mal interprété mon schéma dimensionnel et j'ai fait une erreur lors de la couche silver c qui a fait que j'avais trop de lignes dans ma table de fait. Je m'étais trompé de grain et j'avais pris toutes les catégories donc au lieu d'être en produit * pays j'étais en produit*pays*categorie*date. J'ai donc du modifier mon traitement silver et faire quelques changements sur la table gold de trino car cela ne correspondait plus à mon schéma.

Ressenti :

Confiant, j'ai pu aborder ce que je voulais commencer. J'ai pris du retard sur le livrable 1 et la modélisation mais c'était nécessaire afin de ne pas perdre plus de temps sur le livrable 2/3

Hypothèse :

Il faut qu'ils soient coordonnés dans leur groupe, il y a beaucoup de choses à faire, notamment lorsqu'on découvre donc il faut qu'ils répartissent le travail sur les différentes couches, sur la modélisation l'exploration le traitement etc. sinon ils ne pourront pas rendre le travail à temps. Encore une fois la modélisation est cruciale pour le reste du projet, ça ne sert à rien d'avoir du code python avancé si le rendu des marts ne correspond pas au besoin.

Question :

Je ne comprends pas bien le fonctionnement des requêtes OLAP. Ni l'utilité de ces requêtes et je n'arrive pas à comprendre comment ces requêtes sont formées.

JOURNAL DE BORD — Semaine S4

Rubrique	Ta réponse
Observation marquante	Décris une situation concrète : quel service Docker, quel outil, quel problème ou réussite ?
Interprétation technique	Pourquoi cette situation s'est-elle produite ? Qu'as-tu compris sur l'infrastructure ou les outils ?
Ressenti personnel	Comment tu t'es senti cette semaine — frustré, confiant, motivé ?
Hypothèse émergente	Quel conseil donnerais-tu à un futur étudiant A4 qui commence Stack B ?
Question ouverte	Qu'est-ce que tu ne comprends pas encore ?

Tes réponses :

Observation :

J'ai d'abord réalisé tous les scripts pyspark gold/silver puis effectué les tests. Quand j'ai voulu automatiser le pipeline avec Airflow, je pensais que ça serait assez simple et que je n'aurai qu'à créer les dépendances et à lancer le pipeline. Pas du tout ! J'ai tenté de lancer mais ça a échoué, j'ai dû installer java sur le conteneur airflown installer les librairies pyspark python, remettre les jars etc. Au final j'ai bien mis 1 journée entière pour faire fonctionner le dag airflow, et il s'avère que ça fonctionne plutôt bien finalement. C'est juste qu'il y a eu beaucoup plus d'imprévu non indiqués dans le workshop mais c'est bien, ça favorise la recherche personnelle et la résolution de réels problèmes.

Interprétation :

Tout simplement car a l'installation on ne se préoccupe pas encore de la partie airflow, on fait donc un conteneur « classique » ou rien n'est configuré et quand on veut commencer à l'utiliser il manque des choses. Tant que ce n'est pas un problème de docker qui ne se lance pas etc, et que c'est vraiment à l'intérieur du conteneur qu'il faut rajouter des choses je trouve ça pertinent car ça nous force à chercher la solution

Ressenti :

Confiant et motivé, c'était la semaine vraiment technique appliquée au projet avec toute la transformation, le stockage etc. ça motive de réaliser qu'on a réussi a bien faire le gold silver et ça pousse pour la semaine prochaine a concrétiser avec la visualisation et la réponse aux besoins.

Hypothèse :

Bien se renseigner sur le fonctionnement de chaque outil, des prérequis car c'est ce qu'il manque beaucoup dans cette stack, on installe par défaut mais il faut rajouter pas mal de choses. Aussi prendre le temps de comprendre chaque étape car sinon ça devient compliqué de debug quand on ne sait pas ce que l'on fait.

Question :

Je ne comprends pas trop la différence entre airflow et prefect de jeremy.

5. Formulaire de consentement RGPD

Ce formulaire est obligatoire. Aucune donnée de recherche ne sera collectée avant sa signature.

Je soussigné(e) DESROUSSEaux Tom, stagiaire au CESI dans le cadre du Bloc Big Data, consens à la collecte et au traitement des données suivantes dans le cadre de la recherche DBR menée par Sonia Sikken et Mickael Delamare (CESI LINEACT) :

- Questionnaires de charge cognitive CLT (4 questionnaires hebdomadaires)
- Grilles d'auto-observation hebdomadaires (4 grilles)
- Journal de bord hebdomadaire (4 entrées)
- Auto-positionnement initial et final (7 domaines)
- Entretien semi-directif enregistré (S5, environ 30 minutes)
- Fiche démographique anonymisée

Je comprends que toutes les données sont anonymisées, que je peux retirer mon consentement à tout moment sans conséquence sur mon stage, et que les données sont utilisées uniquement à des fins de recherche académique.

Nom et prénom	DESROUSSEaux Tom
Date	08/06/2026
Signature	
Signature de l'encadrante	

6. Règles de fonctionnement

6.1 Validation par boucle

Chaque boucle est validée par l'encadrante avant de passer à la suivante. Présentation orale du livrable (15 min). Sans validation, la boucle est à retravailler.

6.2 Utilisation des IA génératives

Autorisée pour débloquer une erreur Docker ou comprendre un concept. **Interdite** pour générer directement les livrables. Toute utilisation doit être tracée dans la grille d'auto-observation — c'est une donnée de recherche.

6.3 Contacts

Interlocuteur	Rôle	Pour quoi ?
Sonia Sikken	Encadrante pédagogique	Validation livrables, blocages techniques, questions sur le projet
Mickael Delamare	Co-encadrant recherche	Questions instruments de recherche, entretien S5