

Workshop Livrable 3 – Stack B - TOM

NutriScan - Dashboard Superset, storytelling, note architecture et poster

Contexte

Ce document constitue le support de préparation et de restitution du Livrable 3 de NutriScan. Il s'appuie sur la Stack B mise en oeuvre : ingestion PySpark, stockage MinIO, orchestration Airflow, exposition SQL avec Trino et visualisation dans Apache Superset.

Périmètre du livrable

Le livrable couvre le dashboard Superset, le support storytelling, la note de synthèse architecture et le poster de restitution. Les six requêtes OLAP Trino ont déjà été réalisées et documentées dans le Livrable 2, elles ne sont donc pas reprises comme production distincte ici.

1. Contenu attendu du Livrable 3

Le Livrable 3 constitue la restitution finale du projet NutriScan. Il regroupe quatre productions principales :

Production	Description
Dashboard Apache Superset	Connecté à Trino. 3 sections distinctes, une par axe analytique, 2 profils utilisateurs, 5 visualisations minimum et 3 filtres natifs interactifs.
Support storytelling	2 narrations : nutritionniste et analyste marché. Réponses explicites aux 3 questions posées par la CTO et au moins 3 recommandations actionnables.
Note de synthèse architecture	Analyse des limites de la Stack B, comparaison Stack A vs Stack B, recommandations cloud avec coût estimé, position sur semantic layer et LLM.
Poster de restitution	Support visuel d'une page retraçant tout le pipeline : ingestion, Silver, Gold, Airflow, Trino et Superset.

À propos des requêtes OLAP

Les 6 requêtes OLAP Trino ont été documentées dans le Livrable 2 avec leurs plans EXPLAIN ANALYZE. Elles servent de support technique à l'analyse de performance mais ne constituent pas une production séparée dans ce livrable.

2. Rappel de la Stack B NutriScan

Couche / outil	Rôle dans le projet
Open Food Facts	Source de données alimentaires : produits, marques, catégories, pays, Nutri-Score, NOVA et nutriments.
PySpark	Lecture, nettoyage, normalisation et transformation distribuée des données.
MinIO	Stockage objet local compatible S3 pour les couches RAW, Silver et Gold.
Airflow	Orchestration du pipeline : staging, dimensions, table de faits et tests qualité.
Trino	Moteur SQL distribué, exposition du schéma hive.nutriscan_gold et des vues sémantiques.
Superset	Restitution visuelle sous forme de dashboards interactifs.

Modèle Gold

La couche Gold repose sur un modèle en étoile composé des dimensions dim_product, dim_brand, dim_category, dim_country et dim_date, reliées à la table fact_nutrition. Le grain retenu est : 1 ligne = 1 produit × 1 pays.


Partie 1 - Dashboard Apache Superset

Le dashboard Superset est connecté à Trino via le schéma hive.nutriscan_gold. Il est organisé en trois sections correspondant aux trois axes analytiques du projet.

Élément	Paramétrage retenu
Outil	Apache Superset, connecté à Trino.
Connexion	Schéma hive.nutriscan_gold, tables Gold et vues sémantiques.
Filtres natifs	Pays, Catégorie, Marque et Période.
Publics	Nutritionniste et analyste marché.
Organisation	3 sections : qualité nutritionnelle, marché et marques, analyse temporelle.

1.1 Structure du dashboard

Axe	Public principal	Visualisations retenues	Objectif métier
Axe 1 - Qualité nutritionnelle	Nutritionniste	KPI Nutri-Score moyen, KPI produits analysés, donut Nutri-Scores, carte pays, barres catégories, synthèse nutritionnelle.	Comprendre la qualité nutritionnelle générale et repérer les différences par catégorie ou pays.
Axe 2 - Marché et marques	Analyste marché	KPI marques, top marques, bubble chart, treemap, tableau résumé.	Comparer les marques selon volume, présence et positionnement nutritionnel.
Axe 3 - Analyse temporelle	Deux profils	KPI produits actifs, complétude Nutri-Score, évolution produits, évolution Nutri-Score, heatmap, répartition annuelle.	Suivre l'évolution du catalogue et de la qualité nutritionnelle dans le temps.



Filters

+ ADD/EDIT FILTERS

Pays

379 options

Marque

1000 options


Catégorie

1000 options

Date

No filter

Filters out of scope (0)



Filters

+ ADD/EDIT FILTERS

Pays

379 options

Marque

1000 options


Catégorie

1000 options

Date

No filter

Filters out of scope (0)



Partie 2 - Support de storytelling

Le support de storytelling traduit les résultats du dashboard en discours métier pour un public non technique. Il doit répondre explicitement aux trois questions posées par la CTO.

Exemples de questions posées par la CTO

1. Quelle est la qualité nutritionnelle générale des produits analysés, et comment se situe-t-elle par catégorie ou par pays ?
2. Quelles marques se distinguent, positivement ou négativement, sur le plan nutritionnel ?
3. Comment la qualité nutritionnelle et le volume de produits référencés évoluent-ils dans le temps ?

2.1 Narration 1 - Profil nutritionniste

La narration nutritionniste se concentre sur la qualité globale des produits, les catégories à surveiller et les écarts entre pays.

Question CTO	Réponse narrative côté nutritionniste
Qualité nutritionnelle générale	Le donut des Nutri-Scores et le KPI Nutri-Score moyen permettent de résumer rapidement la qualité générale des produits analysés. Les catégories dont le score moyen est le plus élevé doivent être surveillées en priorité.
Marques qui se distinguent	Même si l'axe marque relève davantage de l'analyste marché, le nutritionniste peut repérer les marques qui concentrent des produits moins bien notés et proposer des pistes de reformulation.
Évolution temporelle	L'évolution du Nutri-Score moyen dans le temps permet de vérifier si le portefeuille de produits s'améliore ou se dégrade progressivement.

2.2 Narration 2 - Profil analyste marché

La narration analyste marché met l'accent sur le volume de produits par marque, le positionnement nutritionnel et la dynamique temporelle du catalogue.

Question CTO	Réponse narrative côté analyste marché
Qualité nutritionnelle générale	La qualité nutritionnelle devient un indicateur de positionnement marché : les pays ou catégories les mieux notés peuvent servir de benchmark.
Marques qui se distinguent	Le top marques, le bubble chart et le tableau résumé permettent d'identifier les marques les plus visibles et celles qui combinent volume important et bonne qualité nutritionnelle.
Évolution temporelle	Les séries temporelles permettent de suivre l'évolution du catalogue produit et d'identifier les périodes où la qualité moyenne varie.

2.3 Insights actionnables

Insight actionnable	Recommandation concrète	Visualisation d'appui
Prioriser les catégories dont le Nutri-Score moyen est le plus élevé	Mettre en place une analyse détaillée des catégories les moins favorables afin d'identifier les nutriments responsables et proposer des pistes de reformulation.	Nutri-Score moyen par catégorie
Comparer les pays pour identifier des marchés de référence	Utiliser les pays mieux positionnés comme benchmark et analyser les différences de portefeuille produit ou de déclaration nutritionnelle.	Carte Nutri-Score moyen par pays
Identifier les marques à fort volume et faible performance nutritionnelle	Construire une liste de marques prioritaires pour des actions de sensibilisation, reformulation ou suivi commercial.	Bubble chart et tableau résumé des marques

Surveiller l'évolution temporelle du Nutri-Score moyen	Mettre en place un suivi périodique pour détecter rapidement une dégradation ou une amélioration du portefeuille produit.	Area chart Nutri-Score moyen dans le temps
--	---	--

Partie 3 - Note de synthèse architecture

Cette note prend du recul sur l'architecture Stack B mise en œuvre, ses limites en conditions locales et ses évolutions possibles vers des services managés.

Section A - 3 composants qui atteindraient leurs limites en premier

Composant	Limites probables	Conditions de saturation	Impact
Trino en local	Capacité CPU et mémoire limitée à la machine locale. Absence de scaling horizontal réel dans l'environnement projet.	Requêtes concurrentes, COUNT DISTINCT fréquents, dashboards avec plusieurs visualisations, gros volumes ou rafraîchissements rapprochés.	Temps de réponse élevés, timeouts Superset, saturation Docker.
Infrastructure Docker + MinIO	Un seul nœud local, pas de réplication, pas de haute disponibilité, ressources disque et I/O limitées.	Pipeline Airflow/PySpark en parallèle avec lectures Trino/Superset, forte activité MinIO, stockage Gold volumineux.	Ralentissements, indisponibilité locale, difficulté à garantir la fiabilité.
Superset en local	Service local non dimensionné pour beaucoup d'utilisateurs concurrents et dépendant directement des performances Trino.	Plusieurs utilisateurs, filtres interactifs sur de nombreuses marques, dashboards ouverts pendant un run Airflow.	Expérience utilisateur dégradée, requêtes multiples simultanées, chargements longs.

Section B - Comparaison Stack A vs Stack B

Critère	Stack A	Stack B mise en œuvre	Analyse
Prise en main	Apache Hop, DuckDB, dbt, Prefect, Power BI : stack plus accessible pour un poste local.	PySpark, MinIO, Airflow, Trino, Superset : stack plus proche d'une architecture Big Data.	Stack A est plus simple pour démarrer ; Stack B est plus représentative d'un data lake analytique.
Scalabilité	DuckDB est très performant localement mais reste un moteur embarqué.	Trino, PySpark et MinIO sont pensés pour des architectures distribuées, même si le projet reste local.	Stack B a un meilleur potentiel de passage à l'échelle.
Orchestration	Prefect est simple, lisible et rapide à mettre en place.	Airflow est plus lourd mais plus standard pour des pipelines planifiés et industrialisables.	Airflow apporte une logique plus proche de la production.
Maintenance	Moins de composants, donc maintenance plus simple.	Plus de composants Docker, dépendances réseau et configuration plus complexes.	Stack B demande plus d'effort d'exploitation.
Visualisation	Power BI est très mature pour le storytelling et le partage.	Superset est open source, adapté aux dashboards SQL et à Trino.	Power BI est plus confortable côté design, Superset s'intègre mieux à une pile open source.

Section C - Recommandations avec alternative et coût estimé

Limite observée	Alternative proposée	Principe	Coût estimé	Pertinence pour NutriScan
Trino local limité	Starburst Galaxy ou	Moteur SQL managé pour	Starburst : à partir de	Pertinent si NutriScan garde

	Athena	interroger des données sur un data lake sans gérer le cluster.	0,50 \$/crédit en Pro. Athena : environ 5 \$/To scanné.	une logique data lake Parquet et veut éviter la gestion locale de Trino.
Docker + MinIO sans haute disponibilité	Stockage objet cloud + catalogue managé	Remplacer MinIO local par S3/GCS/Azure Blob et utiliser un catalogue de métadonnées managé.	Quelques euros à dizaines d'euros par mois pour quelques dizaines/centaines de Go, selon stockage et lectures.	Pertinent pour fiabiliser le stockage et séparer les traitements du poste local.
Superset local limité	Power BI Service ou Superset hébergé	Héberger les dashboards dans un service partagé avec accès utilisateurs et rafraîchissement planifié.	Power BI Pro : 12,10 € HT/utilisateur/mois en France ou 14 \$/utilisateur/mois selon tarification US.	Pertinent pour rendre les tableaux de bord accessibles à des utilisateurs métier.
Besoin entrepôt managé	BigQuery ou Snowflake	Entrepôt analytique serverless ou managé, adapté aux requêtes OLAP et à la montée en charge.	BigQuery : 1 To de requêtes gratuit/mois puis environ 6,25 \$/TiB scanné. Snowflake : environ 2 \$/crédit Standard + stockage.	Pertinent si NutriScan veut privilégier simplicité, scalabilité et moins d'administration.

Lecture des coûts

Les coûts indiqués sont des ordres de grandeur et doivent être recalculés selon la région cloud, le volume mensuel scanné, le nombre d'utilisateurs et la fréquence de rafraîchissement. Pour le projet local NutriScan, un budget cloud de démonstration resterait probablement faible, mais il augmenterait rapidement avec des dashboards très consultés ou des scans complets répétés.

Section D - Semantic layer et LLM

Une semantic layer bien construite facilite l'usage d'un LLM parce qu'elle expose des concepts métier propres plutôt que des tables brutes. Dans NutriScan, les tables Gold et les vues sémantiques réduisent l'ambiguïté : le modèle peut comprendre plus facilement des notions comme produit, marque, pays, catégorie, Nutri-Score moyen ou taux de complétude.

Le concept de "chat with your data" correspond à une interface conversationnelle dans laquelle un utilisateur pose une question en langage naturel, puis un LLM traduit la demande en requête SQL ou interroge une couche sémantique contrôlée. Pour NutriScan, ce mécanisme pourrait être activé avec un outil de type agent analytique connecté à Trino, à Superset ou à une semantic layer documentée.

Les tables Gold et les vues sémantiques sont déjà partiellement utilisables par un LLM, car elles sont structurées autour d'un modèle en étoile et de noms métier explicites. Cependant, une utilisation fiable nécessiterait de compléter la documentation des métriques, de formaliser les jointures autorisées et de limiter l'accès direct aux colonnes trop techniques ou ambiguës.

Élément NutriScan	Utilité pour un LLM	Limite actuelle
Tables Gold	Structure relationnelle claire avec dimensions et table de faits.	Besoin de documenter explicitement les relations et le grain.
Vues sémantiques	Métriques pré-agrégées plus simples à interroger en langage naturel.	Toutes les métriques ne sont pas encore formalisées comme définitions métier.
Dashboard Superset	Les axes analytiques reflètent déjà les usages métier.	Un LLM ne peut pas interpréter correctement les visualisations sans métadonnées associées.

Conclusion de la note architecture

La Stack B est plus complexe à mettre en place qu'une stack locale légère, mais elle est cohérente avec les objectifs Big Data du projet. Elle permet de manipuler des volumes importants, de structurer un data lake, d'orchestrer les traitements avec Airflow et d'exposer les données avec Trino. Ses limites principales viennent du fait que l'exécution reste locale : absence de haute disponibilité, ressources limitées et concurrence entre les services Docker. Une migration progressive vers des services managés permettrait de conserver la logique technique du projet tout en améliorant la fiabilité, la scalabilité et le partage aux utilisateurs métier.

Partie 4 - Poster de restitution

Le poster de restitution ne se limite pas au dashboard. Il doit retracer toute la chaîne de traitement : source Open Food Facts, ingestion PySpark, stockage MinIO, nettoyage Silver, modélisation Gold, orchestration Airflow, exposition Trino et restitution Superset.

Bloc du poster	Contenu attendu
Titre et contexte	NutriScan : plateforme Big Data pour analyser les produits Open Food Facts.
Ingestion	Source Open Food Facts, traitement PySpark et stockage MinIO RAW.
Silver	Nettoyage, déduplication, standardisation des marques et pays, extraction des nutriments.
Gold	Modèle en étoile, dimensions, fact_nutrition et grain produit × pays.
Airflow	DAG simplifié : staging, dimensions, table de faits, tests qualité.
Trino	Schéma hive.nutriscan_gold et vues sémantiques pour l'analyse.
Superset	3 axes analytiques, 2 profils utilisateurs, filtres et dashboards interactifs.
Chiffres clés	4,7 M lignes dans fact_nutrition, 4,5 M produits, 347 K marques, 384 pays, 35 K catégories.



4.7 M
lignes dans
fact_nutrition



4.5 M
produits
alimentaires



4.5 M
produits
alimentaires



384
pays / régions
couverts



35K
catégories
alimentaires



3
axes
analytiques



NutriScan

1 INGESTION DES DONNÉES



mail

Flux d'ingestion

Fichiers Parquet

↓

PySpark

↓

MiniO

(RAW Zone)

Technologies

PySpark

MINIO

- Produits alimentaires
- Informations nutritionnelles
- Marques, catégories, pays
- Nutri-Score, NOVA Score

2 Couche Silver


Standardisation et transformation des données brutes.

Principaux traitements

- ✓ Suppression des doublons (produits, marque, catégorie)
- ✓ Normalisation des marques (MA)
- ✓ Normalisation des pays (MIN)
- ✓ Gestion des valeurs manquantes et aberrantes
- ✓ Extraction des nutriments clés
- ✓ Sélection de la catégorie & de la marque principale
- ✓ Conservation des pays de chaque produits

3 Couche Gold

Modélisation des data marts



4 Orchestration Airflow

Airflow automatise l'ensemble du pipeline de bout en bout.

DAG simplifié

STAGING (PySpark)

- sig_products
- sig_nutrition
- sig_brands
- sig_category
- sig_countries
- sig_date

↓

DIMENSIONS GOLD

(dim_product, dim_brand, dim_category, dim_country, dim_date)

↓

TABLE DE FAITS

(fact_nutrition)

↓

TESTS QUALITÉ

(intégrité, complétude, doublons, anomalies)

↓

Fréquence d'exécution : tous les jours à 12h

Relance automatique : 1 retry après 5 minutes



5 Dashboard & Exploration

Trino permet d'interroger les données Gold stockées dans MiniO.



Rôle

- ✓ Moteur SQL distribué et rapide
- ✓ Accès direct aux fichiers Parquet du Data Lake
- ✓ Exécution d'analyses OLAP
- ✓ Création de vues sémantiques pour la BI

↓

Schéma

hive.nutriscan_gold

↓

Vues sémantiques créées

- sem_nutriscore_moyen
- sem_sel_moyen_categorie
- sem_pct_produits_nutriscore_a
- sem_nutriscore_moyenne_mobile
- ... et autres vues métiers

6 QUALITÉ DES DONNÉES

Points forts

- ✓ Clés techniques uniques dans toutes les dimensions
- ✓ Intégrité référentielle vérifiée (0 clé orpheline)
- ✓ Grain produit x pays respecté
- ✓ 0 doublon sur le grain produit x pays
- ✓ Dimensions complètes et cohérentes

Limites restantes

- ⚠ Nutri-Score manquant pour certains produits
- ⚠ Certaines marques ou catégories absentes
- ⚠ Valeurs nutritionnelles aberrantes héritées du RAW
- ⚠ Complétude variable selon les nutriments



7 RESTITUTION ET ANALYSE AVEC SUPERSET

Outil de BI



Connecté à Trino pour explorer les données en temps réel via des tableaux de bord interactifs et des filtres dynamiques.

3 AXES ANALYTIQUES



Axe 1
Qualité nutritionnelle
Distribution des Nutri-Scores
Comparaison par catégorie et par pays



Axe 2
Marché et marques
Classement des marques
Positionnement nutritionnel




Axe 3
Analyse temporelle
Évolution du nombre de produits et du Nutri-Score

PROFILS UTILISATEURS



Nutritionniste
Analyse nutritionnelle et qualité des produits



Analyste marché
Suivi des marques, catégories et pays



CONCLUSION

NutriScan fournit une chaîne complète et automatisée permettant de transformer des données alimentaires brutes en indicateurs nutritionnels fiables et exploitables, de l'ingestion Open Food Facts jusqu'à leur restitution interactive dans Superset.

